

HƯỚNG DẪN & GIẢI THÍCH THUẬT NGỮ HỆ THỐNG GIÁM SÁT ESG GREENWASHING

Tài liệu giải thích thuật ngữ, thang đo rủi ro và phương pháp luận dành cho Chuyên gia Thẩm định & Hội đồng Đánh giá

1. TỔNG QUAN HỆ THỐNG 3 AGENT (3-AGENT SYSTEM ARCHITECTURE)

Hệ thống ứng dụng kiến trúc 3 Agent AI độc lập phối hợp nhằm phát hiện và giám sát rủi ro Greenwashing (Tẩy xanh) trong Báo cáo Phát triển Bền vững (ESG) của doanh nghiệp:

- Agent 1 (ESG Claim Analyzer): Quét toàn bộ văn bản báo cáo ESG, phát hiện các phát biểu môi trường nghi vấn Greenwashing và phân loại theo 4 nhóm Indicator.
- Agent 2 (Devil's Advocate): Phản biện độc lập tranh luận với Agent 1 để bảo đảm không bị ảo giác (hallucination) hoặc cảnh báo quá mức. Hai Agent lặp lại cuộc tranh luận cho đến khi đạt đồng thuận.
- Agent 3 (Incident Matcher & Search API Validation): Sử dụng Google Custom Search API / Live Web Search API cào dữ liệu báo chí và thông báo xử phạt thực tế để đối chiếu phán đoán AI với thực tế đời thực.

2. GIẢI THÍCH CHI TIẾT CÁC THUẬT NGỮ CHÍNH (GLOSSARY)

Total Claims Detected (Tổng số Claims phát hiện):

Tổng số tuyên bố, cam kết hoặc thông điệp về môi trường/ESG có dấu hiệu nghi vấn hoặc cần kiểm chứng được Agent 1 phát hiện từ các đoạn văn bản (chunks) trong báo cáo ESG.

Risk Levels & Risk Calibration (Các mức độ Rủi ro):

- [High Risk] (Rủi ro Cao): Tuyên bố mâu thuẫn số liệu môi trường nghiêm trọng; đưa ra cam kết Net Zero / 100% tái chế rất lớn nhưng hoàn toàn KHÔNG có lộ trình, mốc thời gian hay số liệu kiểm chứng.
- [Medium Risk] (Rủi ro Trung bình): Cam kết môi trường cụ thể nhưng thiếu số liệu xác minh độc lập, hoặc thông tin ngôn ngữ mập mờ, thiếu minh bạch.
- [Low Risk / None] (Rủi ro Thấp / Không rủi ro): Thông điệp truyền thông chung, sứ mệnh doanh nghiệp, thành tựu đã được chứng nhận rõ ràng (ví dụ: ISO 14001, chứng nhận Net Zero từ tổ chức độc lập).

4 ESG Indicators (4 Nhóm Chỉ số Rủi ro Greenwashing):

- Selective Disclosure (Giấu thông tin xấu): Nhấn mạnh điểm xanh nhỏ nhưng che giấu tác hại/vi phạm môi trường tiêu cực.
- Hollow Promise (Cam kết rỗng): Đưa ra cam kết lớn (Net Zero, 100% giảm nhựa...) nhưng không có tiến triển, không có mốc thời gian rõ ràng.
- Misconduct (Sai phạm số liệu): Số liệu môi trường bất thường, thổi phồng hoặc mâu thuẫn giữa các trang báo cáo.
- Misleading Presentation (Ngôn ngữ mập mờ): Dùng nhãn 'xanh 100%', 'thân thiện môi trường', 'thuần tự nhiên' mà không có chứng nhận hợp lệ.

3. CHỈ SỐ ĐỒNG THUẬN COHEN'S KAPPA (κ - INTER-RATER AGREEMENT)

Công thức toán học chuẩn: $\kappa = (p_o - p_e) / (1 - p_e)$

Bảng xếp hạng mức độ đồng thuận theo chuẩn Landis & Koch (1977):

Giá trị Cohen's Kappa (κ)	Mức độ Đồng thuận	Ý nghĩa thực tế trong Hệ thống
1.00	Perfect agreement	Đồng thuận tuyệt đối giữa Agent 1 & Agent 2
0.81 - 0.99	Near perfect agreement	Gần như hoàn hảo (Độ tin cậy rất cao)

0.61 - 0.80	Substantial agreement	Đồng thuận đáng kể (Kết quả phản biện vững chắc)
0.41 - 0.60	Moderate agreement	Đồng thuận vừa phải (Cần xem xét luận điểm)
0.21 - 0.40	Fair agreement	Đồng thuận trung bình (Có sự khác biệt rủi ro)
0.10 - 0.20	Slight agreement	Đồng thuận nhẹ (Bất đồng quan điểm nhẹ)
0.00	No agreement	Bất đồng hoàn toàn (Cần con người can thiệp - HITL)

4. MA TRẬN ĐỐI CHIẾU BÁO CHÍ & ĐỘ CHÍNH XÁC (CONFUSION MATRIX & METRICS)

Trạng thái phân loại	Ký hiệu toán học	Ý nghĩa đánh giá thực tế
Confirmed Risk	True Positive (TP)	AI báo rủi ro và Google Search API tìm thấy báo chí xác nhận đúng.
Unverified Risk	False Positive (FP)	AI báo rủi ro nhưng thực tế chưa có báo chí xác nhận hoặc bị bác bỏ.
Confirmed Clean	True Negative (TN)	AI báo an toàn/rủi ro thấp và thực tế không có bài báo vi phạm.
Missed Risk	False Negative (FN)	AI báo an toàn nhưng thực tế báo chí có tin xử phạt vi phạm.

Công thức chỉ số hiệu năng tổng thể:

- Precision (Độ chính xác): $\text{Precision} = \text{TP} / (\text{TP} + \text{FP})$
- Recall (Độ bao phủ): $\text{Recall} = \text{TP} / (\text{TP} + \text{FN})$
- F1-Score: $\text{F1} = 2 * (\text{Precision} * \text{Recall}) / (\text{Precision} + \text{Recall})$
- Accuracy (Độ chính xác toàn cục): $\text{Accuracy} = (\text{TP} + \text{TN}) / (\text{TP} + \text{FP} + \text{TN} + \text{FN})$